

GUÍA OFICIAL INTEGRAL DE CORRECCIONES Y REEMPLAZOS TEXTUALES: ANEXO 8 (CRISP-DM)

Alineamiento Metodológico, Corrección de Fuga de Datos, Ortografía y Estilo Académico

Tesis: 'Sistema de apoyo al tamizaje de diabetes tipo 2 mediante aprendizaje automático en el Centro de Salud Casa Grande, 2025'

Autores: Ordoñez Reyes, Abraham Benjamín | Quispe Sánchez, Edward Steven | Fecha: Septiembre 2026

1. REEMPLAZOS EN FASE 1 Y FASE 2 DE CRISP-DM

En el **Capítulo I (Párrafos 303 al 307)**, el Objetivo General y los Objetivos Específicos ya fueron reformulados correctamente hacia **eficacia diagnóstica, tiempo promedio y costo operativo**. En el **Anexo 8** deben sustituirse las menciones desactualizadas de 'saturación hospitalaria', 'costos familiares' y N=100.

■ UBICACIÓN EN TESIS: PÁGINA 89 — ANEXO 8 (PÁRRAFOS 1111, 1112 Y 1124) | FASE 1: COMPRENSIÓN DEL NEGOCIO (SPRINT 0)

■ TEXTO ANTIGUO EN ANEXO 8 (DESALINEADO)

- 'Objetivo Principal: Mejorar la detección temprana de la Diabetes Tipo 2 en el Centro de Salud Casa Grande para reducir complicaciones y optimizar recursos.'
- 'Objetivos Específicos: Evaluar la precisión del modelo frente a métodos tradicionales, analizar el impacto en la saturación hospitalaria y determinar el efecto en la reducción de costos familiares.'
- 'Criterio de Éxito Técnico: Se estableció que el modelo debía alcanzar una precisión (accuracy) superior al 90% y un F1-Score competitivo...'

■ TEXTO EXACTO OFICIAL (ALINEADO CON CAPÍTULO I)

- **Objetivo de Negocio Principal (Objetivo General):** Determinar en qué medida la implementación de un sistema de apoyo al tamizaje basado en Machine Learning mejora la eficacia diagnóstica, el tiempo del proceso y el costo operativo en el Centro de Salud Casa Grande, 2025.
- **Objetivos Específicos del Proyecto:**
 1. Evaluar la eficacia diagnóstica del modelo de Machine Learning en la predicción temprana de Diabetes Tipo 2 frente a métodos tradicionales.
 2. Evaluar la reducción del tiempo promedio del proceso de atención y tamizaje clínico del paciente mediante el sistema web.
 3. Evaluar la reducción del costo operativo directo del personal de salud por consulta médica generada mediante el uso del sistema.
- **Criterios de Éxito del Proyecto (CRISP-DM):**
 - **Criterio Técnico (OE1):** Superar la precisión tradicional de línea base (46%), alcanzando en el modelo Random Forest una eficacia diagnóstica superior (86.3% a 90.85% de exactitud y F1 de 0.9126), superando a la Regresión Logística.
 - **Criterio Asistencial (OE2):** Reducir significativamente el tiempo promedio de atención frente a los 38.58 minutos tradicionales (Wilcoxon $p < 0.05$).
 - **Criterio Económico (OE3):** Reducir el costo operativo directo del personal de salud frente a la línea base tradicional de S/ 24.17 por consulta.

■ Instrucción / Dictamen Jurado: Unifica literalmente el Objetivo General (P[303]) y los 3 Objetivos Específicos (P[305-307]) con el Anexo 8.

■ UBICACIÓN EN TESIS: PÁGINAS 89-90 — ANEXO 8 (SOLO PÁRRAFO 1151) | FASE 2: COMPRENSIÓN DE LOS DATOS (SPRINT 1)

■ TEXTO ÚNICO A REEMPLAZAR (PÁRRAFO 1151)

- 'Se obtuvo un conjunto de datos anonimizados de 100 pacientes del Centro de Salud Casa Grande con los campos clave para poder realizar la predicción como:'

■■ Problema observado por el Jurado: Contradecía el tamaño de muestra de 80 y los soportes de cientos/miles de casos en la evaluación del algoritmo.

■ TEXTO EXACTO A PEGAR (SOLO REEMPLAZA PÁRRAFO 1151)

«Para el desarrollo del proyecto se estructuraron dos fuentes de datos complementarias: por un lado, un **dataset clínico de entrenamiento y validación** compuesto por 10,000 registros estandarizados para el aprendizaje del modelo de Machine Learning; y por otro lado, una **muestra asistencial local de 80 pacientes** del Centro de Salud Casa Grande para la evaluación preexperimental de tiempos y costos operativos en consulta. En ambos casos, el análisis y la inferencia predictiva se sustentan en los siguientes campos clave:»

■ INSTRUCCIÓN CLAVE: Las descripciones de las **8 variables (Glucosa, Presión, Embarazos, Grosor, Insulina, BMI, Pedigree y Edad)** SE MANTIENEN INTACTAS a continuación de este párrafo. Solo se cambia este párrafo introductorio.

■ Instrucción / Dictamen Jurado: Resuelve Observaciones 1, 22, 23, 25 y 26. No borres tus 8 variables, están excelentes.

2. REEMPLAZOS EN FASES 3, 4 Y 5 (PREPARACIÓN, MODELADO Y EVALUACIÓN)

■ UBICACIÓN EN TESIS: PÁGINA 90 — ANEXO 8 (SOLO PÁRRAFO 1170, ANTES DE TABLA X) FASE 3: PREPARACIÓN DE DATOS (SPRINT 2 Y 3) — ¡CRÍTICO!	
■ TEXTO ÚNICO A REEMPLAZAR (PÁRRAFO 1170) • 'Para la transformación de los datos se optó por reemplazar los 0 por su valor media de cada campo, y luego limpiar los datos que no lleguen a estar dentro del rango de ciertos campos como:' ■■ Error de Fuga de Datos (Observación 10): Confiesa haber reemplazado ceros por la media antes de entrenar.	■ TEXTO EXACTO A PEGAR (REEMPLAZA PÁRRAFO 1170) «En el proceso de limpieza y formateo de datos, se identificaron registros con valores iguales a cero en variables donde fisiológicamente es imposible un valor nulo (como glucemia, presión arterial, insulina o índice de masa corporal), catalogándose como datos faltantes o inconsistencias biológicas. Para evitar la fuga de información (data leakage), no se realizó ninguna imputación global prematura sobre el conjunto total de datos; en su lugar, se establecieron los rangos biológicos admisibles presentados a continuación y se delegó la imputación por mediana al Pipeline de Scikit-Learn ajustado exclusivamente con los datos de entrenamiento.» ■ INSTRUCCIÓN CLAVE: La Tabla de Rangos Fisiológicos (Glucosa 70-500, Presión 60-180, etc.) SE MANTIENE INTACTA debajo de este párrafo.
■ Instrucción / Dictamen Jurado: Resuelve Observaciones 10, 35 y 36. Elimina la confesión de fuga de datos y preserva la tabla de rangos.	
■ UBICACIÓN EN TESIS: PÁGINAS 91-92 — ANEXO 8 (PÁRRAFOS 1195, 1202-1205 Y CAPTURA) FASE 4: MODELADO, HIPERPARÁMETROS Y ENTRENAMIENTO (SPRINT 4)	
■ FUGA, 100 ÁRBOLES Y CÓDIGO DESACTUALIZADO • P[1195] (Escalaiento): 'Antes de dividir los datos se aplicó StandardScaler...' (Fuga de datos). • P[1202-1203] (Hiperparámetros): Solo 100 árboles sin optimización. • P[1205] (Entrenamiento): 'El algoritmo construyó los 100 árboles de decisión...' (Contradice los 200 árboles). • Captura de Código: Mostraba RandomForestClassifier(n_estimators=100) sin Pipeline ni parámetros óptimos.	■ REEMPLAZOS EXACTOS PASO A PASO (P[1195], P[1205] Y CÓDIGO) • Reemplazo P[1195] (Escalaiento): 'El escalamiento (StandardScaler) se integró en el Pipeline, ajustándose (fit) solo con Train (6,000 casos).' • Hiperparámetros: n_estimators = 200, max_depth = 10, min_samples_leaf = 8, min_samples_split = 16, criterion = 'entropy', class_weight = 'balanced'. • Reemplazo P[1205] (Entrenamiento): «Se ejecutó el método pipeline.fit(X_train, y_train), proceso en el cual se ajustaron de manera secuencial la imputación, la estandarización y los 200 árboles de decisión del ensamble Random Forest, aprendiendo exclusivamente sobre los 6,000 casos de entrenamiento.» • Captura de Código: Reemplazar la imagen por el bloque con Pipeline([...] y n_estimators=200.
■ Instrucción / Dictamen Jurado: Resuelve la contradicción visual entre los 200 árboles del texto y la captura que mostraba 100 árboles.	
■ UBICACIÓN EN TESIS: PÁGINAS 92-93 — ANEXO 8 (PÁRRAFOS 1214 A 1223) FASE 5: EVALUACIÓN DEL DESEMPEÑO (SPRINT 5)	
■ CONTRADICCIONES NUMÉRICAS Y COSTO FAMILIAR • P[1214-1216]: Palabras 'pretest' y 'postest' sueltas, y 'Figura x. Matriz de confusión' con soportes de 117 y 154 despareados. • F1-Score de 61.29% idéntico declarado como 'mejora del 15%'. • P[1223]: Afirmaba 'reducción de costos familiares' (nunca medido).	■ VECTOR COMPLETO DE MÉTRICAS Y CUMPLIMIENTO DE OBJETIVOS • Evaluación en Test Independiente (2,000 casos ciegos): - Exactitud (Accuracy): 90.85% (IC 95%: 89.50% – 92.10%) En muestra local: 86.3%. - Sensibilidad (Recall): 95.50% (detecta a 955 de 1,000 diabéticos). - Especificidad: 86.20% F1-Score: 0.9126 ROC-AUC: 0.9722 MCC: 0.8206. • Reemplazo P[1223] (Costos Operativos): 'Al automatizar la inferencia, el sistema reduce el tiempo asistencial de 38.58 a 0.35 minutos (Wilcoxon p < 0.001) y disminuye el costo operativo del médico de S/ 24.17 a S/ 0.21 por atención asistencial.'
■ Instrucción / Dictamen Jurado: Resuelve Observaciones 2, 3, 4, 5, 30, 41, 42, 51, 52 y 55 (Inconsistencias de métricas y costos).	

3. FASE 6 (DESPLIEGUE), CÓDIGO DEL PIPELINE Y CORRECCIÓN ORTOGRÁFICA

■ UBICACIÓN EN TESIS: PÁGINA 93 — ANEXO 8 (PÁRRAFO 1226) FASE 6: DESPLIEGUE OPERATIVO (SPRINT 6) — ¡ESTABA VACÍA!	
■ SECCIÓN EN BLANCO / TRUNCADA EN EL INFORME • P[1226]: 'Despliegue' (Literalmente figuraba solo el título y pasaba de inmediato al Anexo 9 sin ningún contenido ni explicación de cómo opera el sistema).	■ REDACCIÓN INTEGRAL DE LA ARQUITECTURA EN PRODUCCIÓN • Microservicio REST (Flask Python) : Carga en memoria del pipeline inmutable (diabetes_pipeline.pkl), exponiendo el endpoint POST /predict. • Validación e Ingesta JSON : Mapeo de parámetros (KEYS_MAPPING), imputación y cálculo de probabilidad continua P(Diabetes=1 X) en menos de 50 ms. • Integración Web (Laravel) : Consumo asíncrono desde el módulo de triaje, semáforo visual de alerta temprana y persistencia en Supabase. • Explicabilidad Asistida (Gemini) : Generación de interpretación preventiva contextual transmitiendo únicamente variables numéricas disociadas (cero datos de filiación).
■ Instrucción / Dictamen Jurado: Resuelve Observaciones 44, 45, 8.5 y 64 (Documentación de despliegue, API, pruebas y seguridad clínica).	

Imagen Actualizada del Código de Entrenamiento (Reemplazo de la captura en Fase 4):

```
# 5. Entrenar el Pipeline optimizado (Imputación + Estandarización + Random Forest)
pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler()),
    ('classifier', RandomForestClassifier(
        n_estimators=200, max_depth=10, min_samples_leaf=8,
        min_samples_split=16, criterion='entropy', class_weight='balanced',
        random_state=42
    ))
])

# Ajuste exclusivo con datos de entrenamiento (6,000 casos)
pipeline.fit(X_train, y_train)
print("Pipeline de Machine Learning entrenado exitosamente sin fuga de datos.")
```

Tabla de Correcciones de Ortografía, Términos Coloquiales y Formato Formal en Anexo 8:

Párrafo	Texto Observado (Con Error)	Corrección Inmediata a Realizar	Tipo de Error
1106, 1129, 1147	'Compresión del Negocio' / 'Compresión de los datos'	Cambiar por ' Comprensión del Negocio ' y ' Comprensión de los datos ' (agregar la letra 'n').	Ortográfico
1121	'La posible falta de acceso... pero nada que impida el desarrollo...'	Cambiar por: 'El tratamiento restringido de datos personales en observancia de la Ley N° 29733 mediante disociación anónima.'	Estilo informal
1154	'Si una mujer ha tenido DMG...'	Definir la sigla en su primera mención: ' Diabetes Mellitus Gestacional (DMG) '.	Claridad técnica
1161	'Se utilizaron librerías de Python... en un entorno de Python'	Cambiar por: 'Se utilizaron librerías especializadas como Pandas, NumPy y Matplotlib en Jupyter Notebook.'	Redundancia
1185	'Tabla X. Rango de valores de las variables clave'	Cambiar la letra X por el número real (ejemplo: ' Tabla 8. Rango de valores... ') y agregar nota al pie.	Formato APA 7
1186	'Y aquí una muestra del código de cómo se aplicó:'	Cambiar por: 'A continuación, se presenta la implementación del preprocesamiento dentro del Pipeline:'	Estilo coloquial
1189	'...se seleccionó, entreno y optimizo el algoritmo...'	Colocar tildes en pasado: ' ...se seleccionó, entrenó y optimizó el algoritmo... '.	Ortográfico
1202	'hiper parámetros' (separado)	Escribir junto: ' hiperparámetros '.	Ortográfico
1216	'Figura x. Matriz de confusión' (con letra x minúscula)	Numerar correlativamente (ejemplo: ' Figura 9. Matrices de confusión... ') y agregar nota de fuente.	Formato APA 7

4. DIAGRAMA DE FLUJO Y UBICACIÓN EN EL CAPÍTULO II (PÁG. 38)

El siguiente flujograma modela la inferencia del Pipeline predictivo. Debe insertarse en el **Capítulo II (Subsección 2.3.8: Procedimiento, Pág. 38, Párrafo 508)** para resolver la nota pendiente:




Figura X. Flujograma del proceso de inferencia predictiva y soporte a la decisión clínica mediante el Pipeline de Machine Learning. Integración del Frontend en Laravel (WebDT2), capa de seguridad/disociación (Ley N° 29733), microservicio en Flask (Scikit-Learn) y persistencia en Supabase.

Texto Exacto para insertar en el Capítulo II (Pág. 38, Sección 2.3.8 Procedimiento):

«Para asegurar la reproducibilidad técnica y la robustez del sistema en el entorno asistencial, la ejecución predictiva se modeló como un flujo de datos desacoplado y blindado contra fuga de información. Como se ilustra en la **Figura X**, los datos capturados durante el triaje clínico son disociados en el backend de la aplicación web (WebDT2) en estricta observancia de la Ley N° 29733 y transmitidos mediante una petición HTTP REST asíncrona al microservicio en Python. En este entorno, el vector de variables es procesado de manera atómica por el pipeline serializado (SimpleImputer + StandardScaler + RandomForestClassifier), el cual fue ajustado exclusivamente con datos de entrenamiento. El modelo calcula la probabilidad continua de riesgo $P(\text{Diabetes}=1|X)$ y emite una clasificación binaria basada en un umbral clínico estandarizado de 0.50, retornando el resultado en tiempo real como una herramienta de apoyo al tamizaje asistencial del médico tratante (la adaptación detallada de CRISP-DM con Scrum se documenta exhaustivamente en el **Anexo 8**).»