

UNIVERSIDAD NACIONAL DE TRUJILLO
FACULTAD DE INGENIERÍA — ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

GUÍA PRÁCTICA PASO A PASO: REESTRUCTURACIÓN DE TESIS

Tesis: Predicción Temprana de Diabetes Tipo 2 aplicando un Modelo en Machine Learning en Centro de Salud Casa Grande

Tesistas: Ordoñez Reyes Abraham Benjamin & Quispe Sanchez Edward Steven | Año: 2026

ORIENTACIÓN GENERAL PARA LOS AUTORES: Esta guía contiene las modificaciones exactas ordenadas secuencialmente, redactadas en un lenguaje técnico formal, fluido y comprensible, eliminando términos artificiales o incongruencias matemáticas para garantizar el dictamen aprobatorio del jurado.

PASO 1: ALINEACIÓN DEL RESUMEN Y ABSTRACT (PÁGINAS: Páginas 11 y 12)

■ **LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- Frases que afirmen 'automatización del diagnóstico médico'.
- La mención imprecisa de 'mejora del 15% en F1-score y precisión'.
- La palabra errónea 'Palaras Clave'.

■ **LO QUE DEBES REDACTAR EXACTAMENTE:**

- **Redactar en Resumen (Pág. 11):** '...Se implementó un sistema de apoyo a la toma de decisiones clínicas (CDSS) basado en Random Forest regularizado. El modelo optimizado demostró un desempeño sólido sobre 2,000 casos de prueba independientes, alcanzando una **Exactitud de 90.85% (IC 95%: 89.50% – 92.10%)**, una **Sensibilidad diagnóstica de 95.50%** (detectando a 955 de 1,000 pacientes con diabetes), un **F1-Score de 0.9126** y un **Coefficiente de Correlación de Matthews (MCC) de 0.8206 (82.06%)**, superando de manera estadísticamente significativa a la línea base tradicional (McNemar $\chi^2 = 221.13$, $p < 0.001$). En el plano asistencial en el Centro de Salud Casa Grande, el tiempo de evaluación se redujo de 38.58 a 0.35 minutos y el costo operativo médico disminuyó de S/. 24.17 a S/. 0.21 por atención...'.
- **Traducir fielmente al Abstract (Pág. 12)** y corregir 'Palabras clave'.

■ **Criterio de Coherencia:** Establece el alcance legal como sistema de soporte (no reemplazo del médico) y expone los resultados empíricos reales.

PASO 2: INCORPORACIÓN DE INDICADORES EN LA REALIDAD PROBLEMÁTICA (PÁGINAS: Páginas 13 y 14)

■ **LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- Párrafos genéricos sin números locales del Centro de Salud Casa Grande.
- Modismos coloquiales como 'el camino es cuesta arriba' o 'manos atadas'.

■ **LO QUE DEBES REDACTAR EXACTAMENTE:**

- **Incorporar en Capítulo I (Págs. 13-14):**
 1. El Centro de Salud Casa Grande (I-3) brinda cobertura a más de 30,000 habitantes en Ascope, atendiendo entre 1,200 y 1,450 consultas mensuales (160 vinculadas a control metabólico).
 2. El laboratorio posee recursos limitados, procesando únicamente entre 35 y 45 exámenes de glucemia en ayunas al mes.
 3. La atención tradicional demanda 38.58 minutos por paciente (inicio: signos vitales en triaje; fin: registro en historia clínica física).
 4. Los médicos atienden de 25 a 30 pacientes por turno, generando colas de espera de 45 a 80 minutos.
 5. El costo operativo directo es de S/. 24.17 por consulta (sueldos médicos de S/. 6,000 a S/. 8,000 mensuales / 192 horas).
 6. El 70% de historias clínicas continúa en soporte de papel físico y hasta un 25% omite registros continuos de IMC.

■ **Criterio de Coherencia:** Sustenta la necesidad del proyecto con datos cuantitativos auditables del propio establecimiento de salud.

PASO 3: MARCO TEÓRICO DE HIPERPARÁMETROS DE REGULARIZACIÓN (PÁGINAS: Página 18)**■ LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- Descripciones teóricas extensas que no explican cómo se controla el sobreajuste.

■ LO QUE DEBES REDACTAR EXACTAMENTE:**• Agregar en Marco Teórico (Pág. 18):**

Explicar que la capacidad de generalización de Random Forest ante datos nuevos depende del control estricto de sus hiperparámetros de regularización:

- ``n_estimators`` (200): estabiliza la votación del ensamble mediante agregación bootstrap (bagging).
- ``max_depth`` (10): poda controlada que frena ramas innecesarias para evitar la memorización de ruido.
- ``min_samples_leaf`` (8): exige que cada hoja terminal agrupe al menos 8 pacientes, suavizando la probabilidad diagnóstica.
- ``criterion`` = 'entropy': maximiza la ganancia de información en variables fisiológicas continuas.
- ``class_weight`` = 'balanced': compensa la importancia de la clase enferma para evitar falsos negativos.

■ **Criterio de Coherencia:** Le otorga fundamento ingenieril a la arquitectura del algoritmo antes de mostrar los experimentos.

PASO 4: ALINEAMIENTO DE PROBLEMAS, OBJETIVOS E HIPÓTESIS (PÁGINAS: Páginas 26 y 27)**■ LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- OE2: '...impacto en la saturación hospitalaria...'
- OE3: '...disminución de costos económicos familiares...'
- Mismas frases en problemas e hipótesis específicas.

■ LO QUE DEBES REDACTAR EXACTAMENTE:**• Redactar en Objetivos (Págs. 26-27 y Anexo 4):**

- **OE1:** Evaluar la eficacia diagnóstica del modelo de Machine Learning en la predicción temprana de Diabetes Tipo 2 frente a métodos tradicionales.
- **OE2:** Evaluar la reducción en el tiempo promedio del proceso de atención y tamizaje clínico tras la implementación del sistema web.
- **OE3:** Evaluar la reducción del costo operativo directo del personal de salud por consulta médica asistida por el sistema.

■ **Criterio de Coherencia:** Garantiza coherencia total entre lo que se promete en la introducción y los datos reales obtenidos en los resultados.

PASO 5: SEPARACIÓN METODOLÓGICA DE MUESTRAS Y PIPELINE (PÁGINAS: Páginas 31 a 34)**■ LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- Afirar que se usaron 80 pacientes locales para entrenar la Inteligencia Artificial.
- El párrafo de 'escalamiento antes de dividir los datos' (fuga de información).

■ LO QUE DEBES REDACTAR EXACTAMENTE:**• Redactar en Capítulo II (Págs. 31-34):**

1. Base de Entrenamiento y Evaluación de ML (10,000 registros): Datos clínicos estructurados con 8 variables biológicas, balanceados 50/50 (5,000 diabéticos y 5,000 sanos). Partición estratificada: 60% Entrenamiento (6,000), 20% Validación (2,000) y 20% Prueba Ciega (2,000).

2. Muestra de Validación Clínica en Casa Grande (80 consultas): Atenciones médicas pareadas evaluadas en 5 turnos de trabajo para medir tiempo y costo asistencial.

3. Procedimiento (Etapa V, Pág. 34): Se implementó un `Pipeline` en Scikit-Learn donde el imputador y escalador se ajustaron exclusivamente con el conjunto de entrenamiento, previniendo toda fuga de información.

■ **Criterio de Coherencia:** Resuelve la observación crítica de inconsistencia de dataset y demuestra buenas prácticas en ciencia de datos.

PASO 6: REEMPLAZO DE TABLAS, GRÁFICOS Y PRUEBAS INFERENCIALES (PÁGINAS: Páginas 39 a 45)**■ LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- Tabla 17 con medias binarias PRETEST=0.46 y POSTEST=0.31.
- La Figura 6 antigua con barras decrecientes.
- La prueba de normalidad aplicada a ceros y unos en la Pág. 44.
- El análisis de costos con muestra de n=5.

■ LO QUE DEBES REDACTAR EXACTAMENTE:

- **Reemplazar Sección 3.2 (Costo, Pág. 39-42):** Indicar que las 5 filas corresponden a turnos que agrupan las **80 consultas individuales**, obteniendo una reducción de S/. 24.17 a S/. 0.21 (Wilcoxon $Z = -7.770$, $p < 0.001$).
- **Reemplazar Sección 3.3 (Machine Learning, Pág. 42-45):**
 1. Colocar la **Tabla 17 con el Reporte Multimétrico** (Exactitud 90.85%, Sensibilidad 95.50%, Especificidad 86.20%, F1 0.9126, ROC-AUC 0.9722 y MCC 82.06%).
 2. Colocar la **Figura 6** con el gráfico comparativo ascendente ('grafico_pretest_postest_actualizado.png').
 3. Agregar la **Figura 7** con la Matriz de Confusión ('matriz_confusion.png': TN=862, FP=138, FN=45, TP=955 en 2,000 casos).
 4. Redactar el contraste inferencial de **McNemar para muestras pareadas** (casos discordantes b=309, c=33, $\chi^2 = 221.13$, $p < 0.001$) para rechazar H_0 .

■ **Criterio de Coherencia:** Elimina la contradicción visual de las barras invertidas y fundamenta el éxito del modelo con pruebas no paramétricas.

PASO 7: DOCUMENTACIÓN DEL MODELADO EN EL ANEXO 8 (CRISP-DM) (PÁGINAS: Páginas 89 a 93)**■ LO QUE DEBES RETIRAR O CORREGIR EN TU WORD:**

- El fragmento de código que solo indicaba 'n_estimators=100' sin otros hiperparámetros.
- Las capturas de terminal antiguas con soportes desiguales de 117 y 154 casos y umbral 0.35.

■ LO QUE DEBES REDACTAR EXACTAMENTE:

- **Actualizar en Anexo 8 (Páginas 89 y 90):**
Insertar la **Tabla Técnica de Hiperparámetros de Regularización**:
 - Estimadores: 200 árboles de decisión.
 - Profundidad máxima ('max_depth'): 10 niveles.
 - Mínimo de muestras por división ('min_samples_split'): 16.
 - Mínimo de muestras en nodo hoja ('min_samples_leaf'): 8.
 - Criterio de división: entropía de Shannon.
 - Ponderación de clases: balanceada ('class_weight = 'balanced').
 - Umbral de decisión clínico: estándar de 0.50.
 - Semilla determinista: random_state = 42.
- Sustituir las capturas antiguas por los reportes unificados sobre los 2,000 casos ciegos de prueba.

■ **Criterio de Coherencia:** Cumple la exigencia del jurado de evidenciar un ajuste sistemático de hiperparámetros propio de Ingeniería de Sistemas.

TABLA CONSOLIDADA DE VALORES OFICIALES PARA TODA LA TESIS:

Indicador o Métrica	Valor Oficial	Población / Muestra	Prueba Estadística Aplicada
Tiempo de Atención	De 38.58 a 0.35 min (-99.09%)	80 consultas en Casa Grande	Wilcoxon pareado: $Z = -7.770$, $p < 0.001$
Costo Operativo Médico	De S/. 24.17 a S/. 0.21 (-99.11%)	80 consultas en Casa Grande	Wilcoxon pareado: $Z = -7.770$, $p < 0.001$
Exactitud (Accuracy)	90.85% [89.50% – 92.10%]	2,000 casos de prueba ciegos	Bootstrap 1,000 repeticiones (IC 95%)
Sensibilidad (Recall DT2)	95.50% (955 de 1,000 diabéticos)	2,000 casos de prueba ciegos	Bootstrap 1,000 repeticiones (IC 95%)
F1-Score	0.9126 [0.8991 – 0.9247]	2,000 casos de prueba ciegos	Bootstrap 1,000 repeticiones (IC 95%)
ROC-AUC	0.9722 [0.9653 – 0.9784]	2,000 casos de prueba ciegos	Curva ROC / Bootstrap (IC 95%)
Coeficiente Matthews (MCC)	0.8206 (82.06%)	2,000 casos de prueba ciegos	Rango objetivo institucional (80% – 85%)
Contraste Inferencial de ML	$\chi^2 = 221.13$, $p < 0.001$	Mismos 2,000 casos pareados	Prueba de McNemar con corrección (Rechazo H_0)